Duboko učenje i neuronske mreže

Predavanje 1

Prof. dr Zoran Ševarac, FON

Uvod u Deep Learning

Deep learning je grana veštačke inteligencije zasnovana na neuronskim mrežama.

U suštini je vrsta mašinskog učenja koje koristi različite arhitekture neuronskih mreža i može se primeniti na razne vrste podataka - tabelarni podaci, tekst, slike, zvuk, video.

Zato se primenjuju u prepoznavanju slika, razumevanju teksta, prepoznavanju govora i mnoštvu drugih oblasti.

Predstavlja osnov i glavni pravac razvoja savremene veštačke inteligencije.

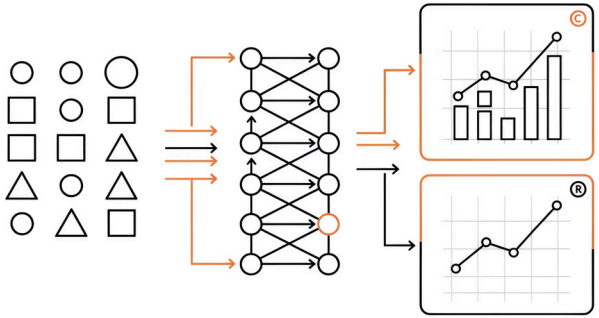

Podsetnik

Mašinsko učenje - Kreiranje modela za rešavanje određene vrste zadataka na osnovu podataka.

Podaci sadrže primere iz kojih primenom algoritamskog postupka tzv. treninga, mogu izvući određeni obrasci, statistka i pravila.

Ukoliko su korišćeni odgovsarajući podaci za trening, model se može uspešno primeniti i na podatke koji nisu korišćeni u treningu, odnosno koje model nije video.

Na taj način model može da nauči nepoznato preslikavanje skupa ulaznih parametara na skup izlaza.

Osnovne vrste zadataka mašinskog učenja

🔵 Klasifikacija

Model dodeljuje ulazne podatke jednoj od unapred definisanih **klasa**. Izlaz je diskretna oznaka ili raspodela verovatnoća.

- Detekcija spama u emailu
- Dijagnoza bolesti (da/ne)
- Prepoznavanje emocija u tekstu
- Prepoznavanje objekata na slici

📈 Regresija

Model predviđa **kontinuiranu numeričku vrednost**. Izlaz je broj, a ne kategorija.

- Predikcija cene nekretnine
- Procena temperature
- Predviđanje prihoda kompanije

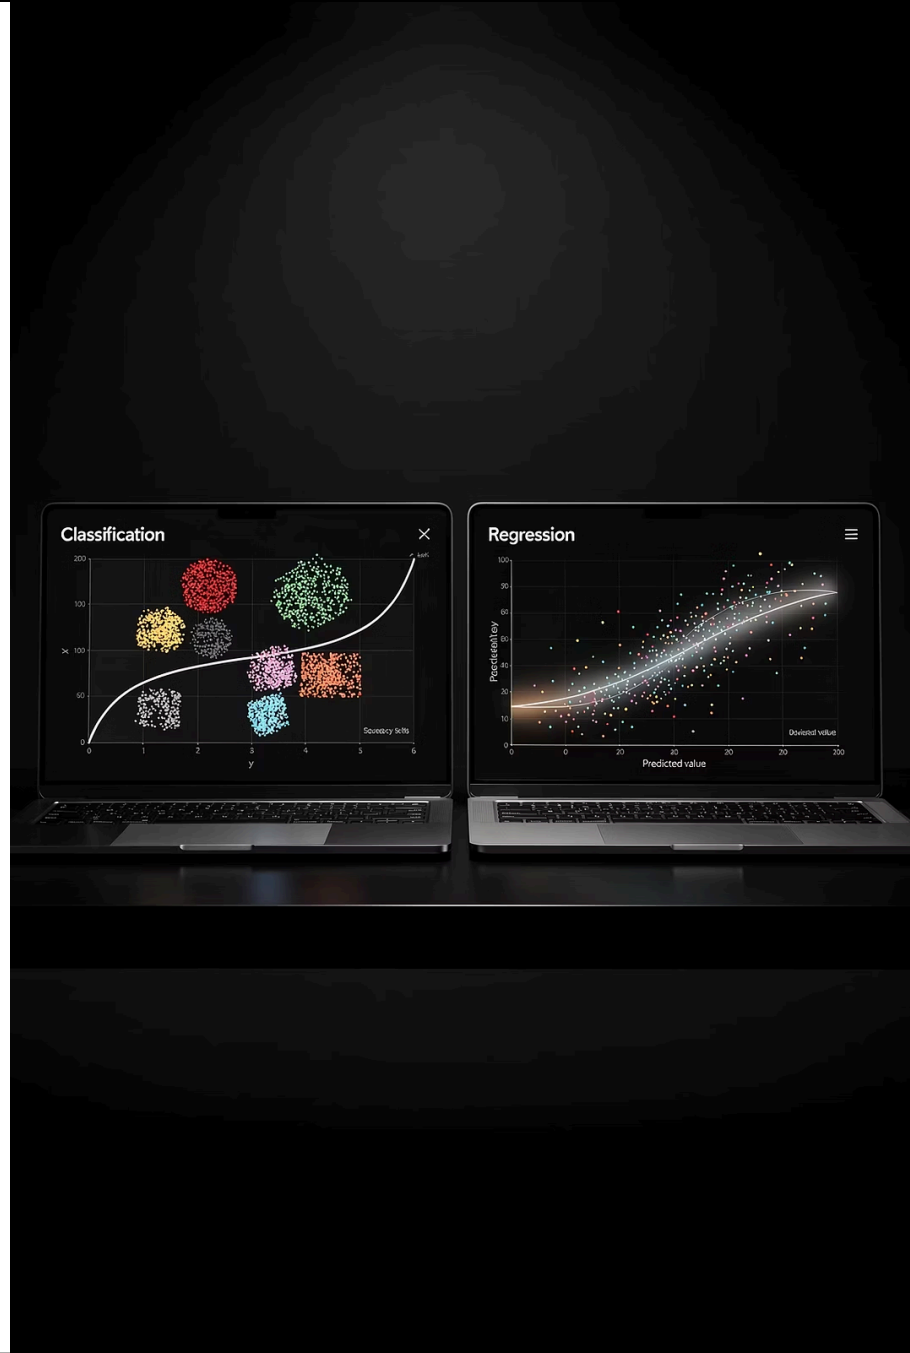

Osnovni pojmovi i komponente u radu sa neuronskim mrežama

- Tenzori
- Arhitektura mreže i slojevi
- Funkcija aktivacije i težinski parametri
- Funkcija greske , Loss Function
- Algoritam za optimizaciju , *Optimizer*

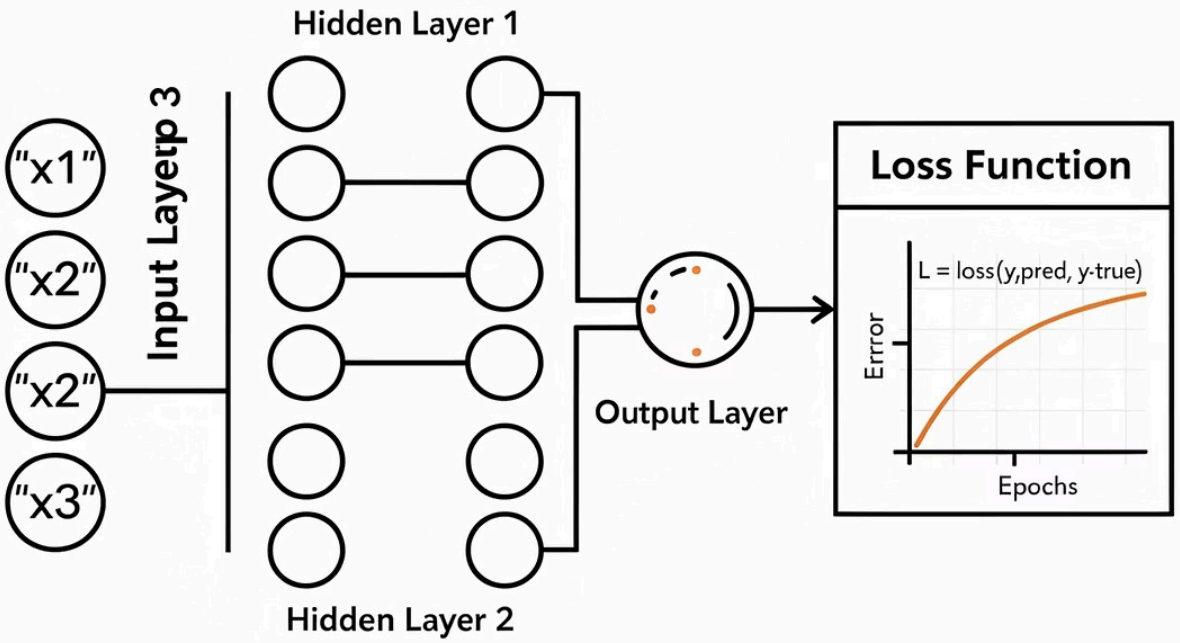

Tenzori

Tenzori su višedimenzionalni nizovi i predstavljaju osnovnu strukturu podataka koja se koristi za predstavljanje i implementaciju neuronskih mreža.

1D Tenzor = Vector

2D Tenzor = Matrica

3D Tenzor= Generalizacija matrice u 3 dimenzije - niz matrica

ND Tenzor = N Dimenyionalni tenzor

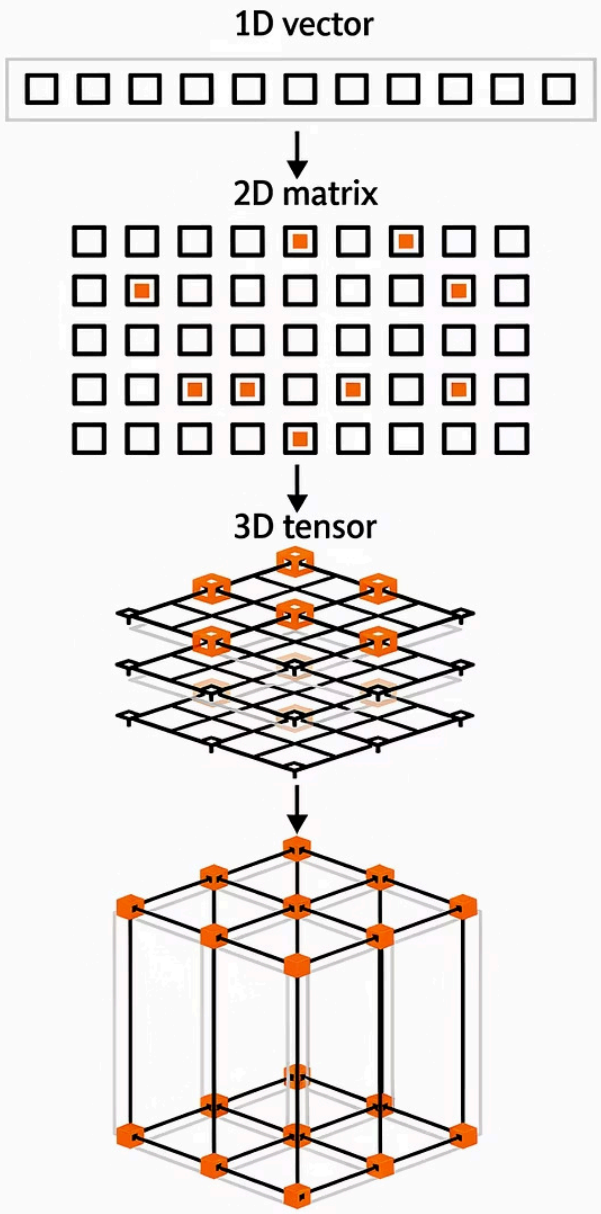

Arhitektura mreže i slojevi

- Svaka neuronska mreža izgrađena je od nekoliko slojeva neurona (*Layer*) koji zajedno definišu strukturu modela.
- Svaki sloj prima ulaz od prethodnog, transformiše ga i prosleđuje sledećem.
- Svi ulazi i izlazi slojeva predstavljaju se kao TENZORI!

Ulazni sloj

Prima sirove podatke — piksele slike, reči teksta ili numeričke vrednosti. Veličina odgovara dimenziji ulaznih podataka.

Skriveni slojevi

Srce mreže. Više skrivenih slojeva omogućava učenje složenih, apstraktnih obrazaca. Dublja mreža = veća slozenost.

Izlazni sloj

Generiše finalni rezultat — klasu, verovatnoću ili numeričku vrednost, zavisno od zadatka.

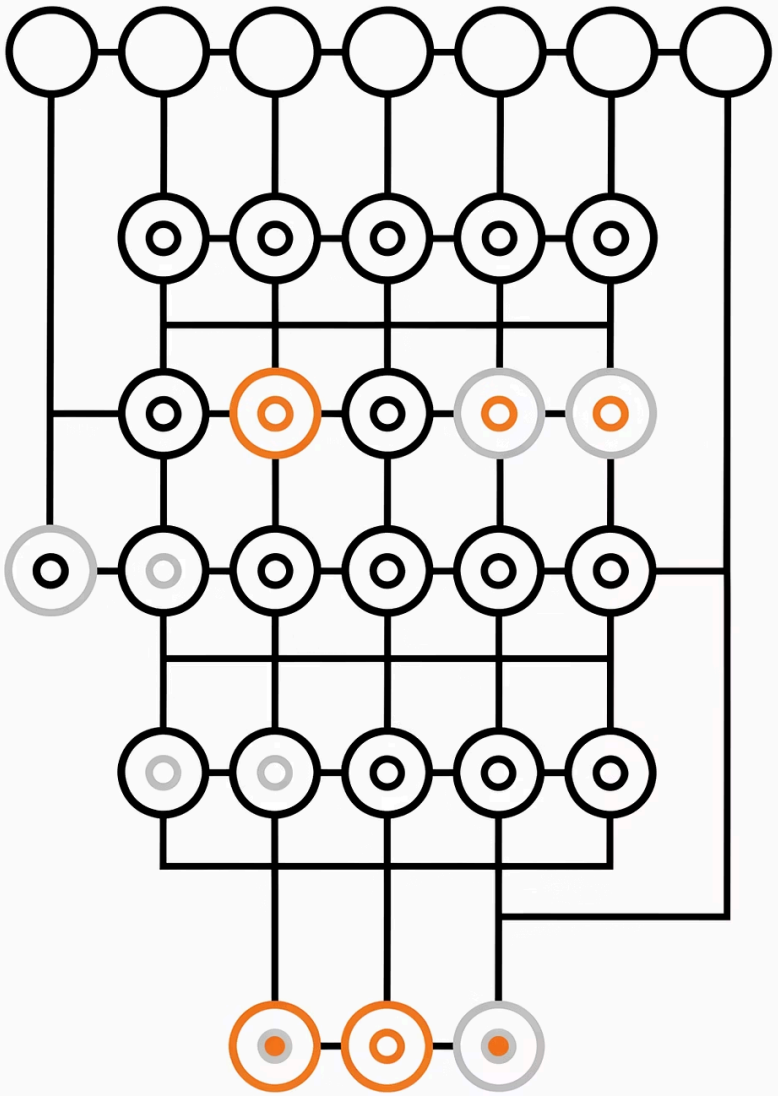

Output

Detalji sloja u neuronskoj mreži

Svaki sloj prihvata tenzor kao ulaz i daje tenzor kao izlaz.

Sadrži

- tenzor težina W (weights)
- konstantnih ulaza B (bias)
- aktivacionu funkciju f

Matematička formula po kojoj računa izlaze je

Y = f(W*X+B)

gde je X ulazni tenzor, a W*X proizvod matrica

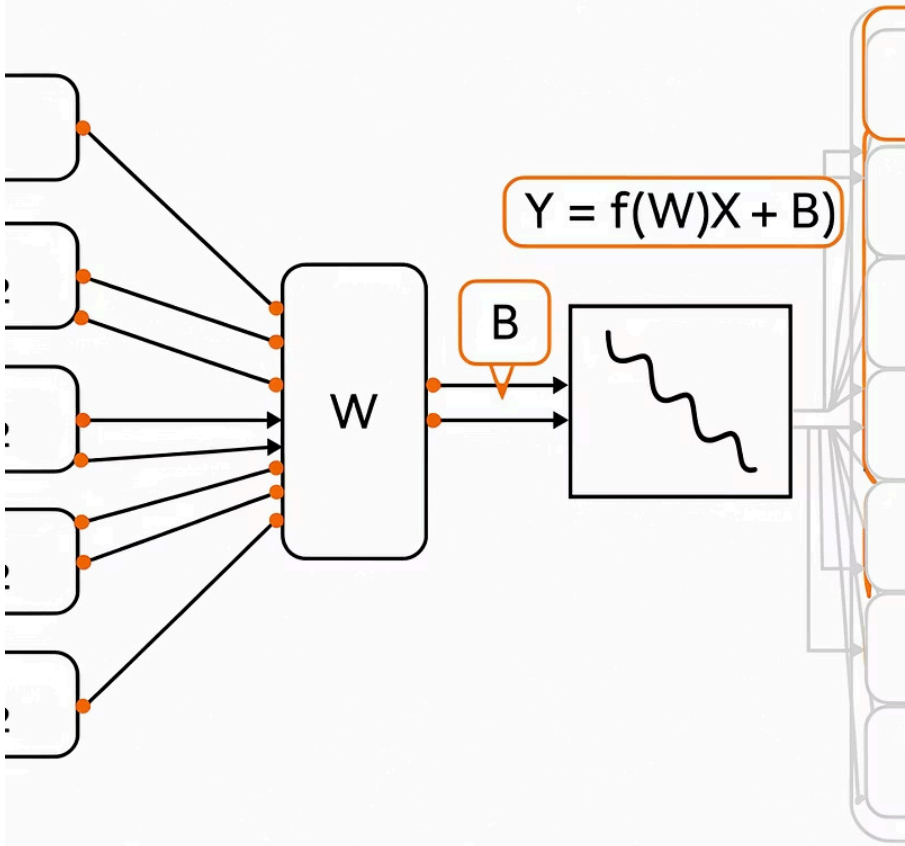

Funkcije aktivacije

Bez funkcija aktivacije, neuronska mreža bi bila samo linearna transformacija — bez obzira na broj slojeva. Aktivacijske funkcije **uvode nelinearnost** i omogućavaju modelu da uči kompleksne odnose u podacima.

ReLU

Rectified Linear Unit. Najčešće korišćena. Propušta pozitivne vrednosti, nulu vraća za negativne. Brza i efikasna.

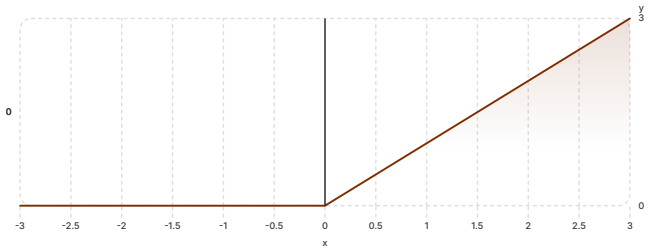

Sigmoid

Mapira vrednosti u opseg (0, 1). Idealna za binarne klasifikacije i izlazne slojeve koji daju verovatnoće.

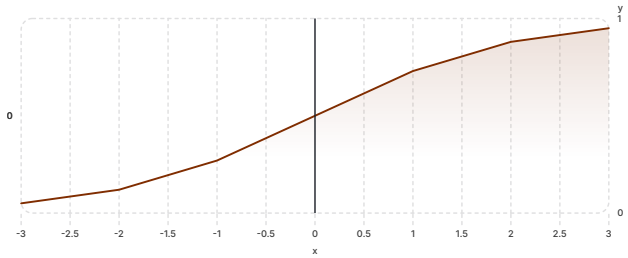

Tanh

Slična sigmoidu, ali u opsegu (−1, 1). Bolja centriranost podataka, češće u skrivenim slojevima.

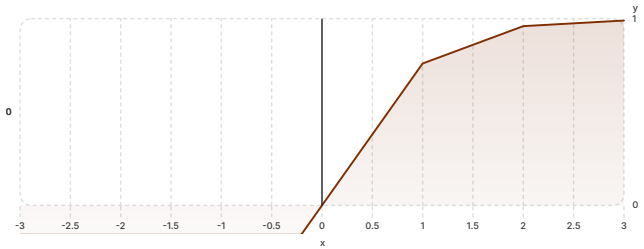

Softmax

Pretvara izlaze u raspodelu verovatnoća koja sumira na 1. Standardna u višeklasnoj klasifikaciji.

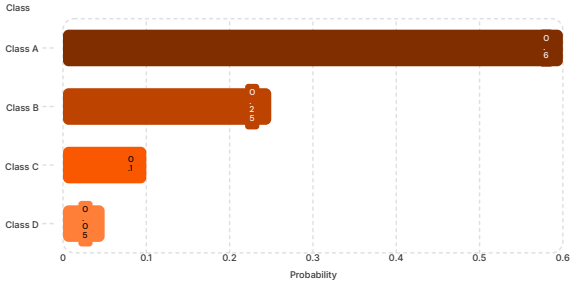

Funkcije greške - Loss funkcija

Loss funkcija (funkcija greške) kvantifikuje **koliko su predikcije modela udaljene od stvarnih vrednosti**.
Trening se svodi na minimizaciju ove vrednosti kroz iterativno podešavanje parametara u slojevima (Weights and Biases).

MSE — Mean Squared Error

Koristi se u zadacima **regresije**. Računa prosečni kvadrat razlike između predviđene i stvarne vrednosti. Kažnjava velika odstupanja više nego mala.

Cross-Entropy Loss

Standardna loss funkcija za **klasifikaciju**. Meri razliku između predviđene raspodele verovatnoća i tačnih oznaka. Što je predikcija sigurnija i tačnija, loss je manji.

PROCES

Trening modela

Trening je iterativan proces u kome model **uči iz podataka** kroz ponovljene prolaze.

Forward Pass

Propagacija unapred — ulazni podaci prolaze kroz mrežu i generiše se predikcija.

Loss računanje

Predikcija se poredi sa stvarnom vrednošću i računa se greška.

Backpropagation

Greška se propagira unazad i težine se ažuriraju.

Ovaj ciklus se ponavlja stotinama ili hiljadama puta kroz epohe treninga, sve dok model ne postigne zadovoljavajuće performanse.

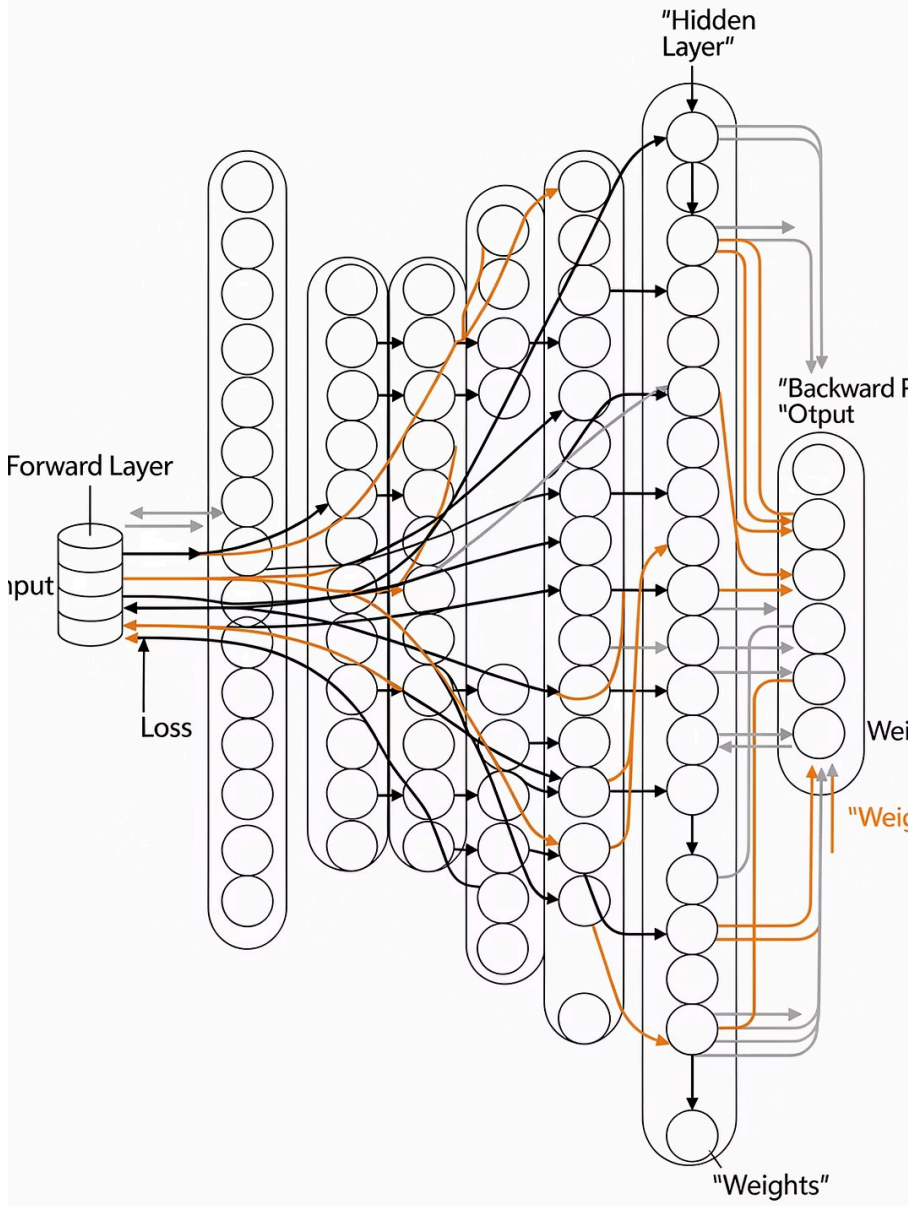

Optimizacija

Optimizacija je proces kojim model **smanjuje grešku** postepenim podešavanjem težina. Algoritmi optimizacije odlučuju kako i koliko brzo mreža uči.

Gradient Descent

Temeljni algoritam optimizacije. Izračunava gradijent loss funkcije i pomera težine u smeru koji smanjuje grešku. Postoji u varijantama: batch, mini-batch i stochastic.

Adam Optimizer

Jedan od najpopularnijih optimizatora. Kombinuje prednosti momentum i RMSProp metoda. Adaptivno prilagođava learning rate za svaki parametar posebno.

Learning Rate

Jedan od najvažnijih hiperparametara. Određuje veličinu koraka tokom optimizacije.

Previše visok → nestabilno učenje;

previše nizak → spor trening.

Predikcija (Inference)

Nakon što je model istreniran, prelazimo u fazu **predikcije** — poznatu i kao inference. U ovoj fazi model više ne uči niti ažurira svoje težine. Jednostavno prima novi, neviđeni ulaz i generiše izlaz koristeći naučene parametre.

→ Zamrznute težine

Svi parametri ostaju fiksni. Nema backpropagation niti ažuriranja — model je u "read-only" modu.

→ Brži od treninga

Inference je računski znatno lakši — izvodi se samo forward pass, bez računa gradijenata.

→ Deployment u praksi

Model se integriše u aplikaciju, API ili uređaj i u realnom vremenu daje odgovore korisnicima.

Evaluacija modela

Dobre metrike evaluacije su ključne — one nam govore **koliko dobro model zaista radi** na podacima koje nikad ranije nije video. Izbor metrike zavisi od tipa zadatka.

Metrike za klasifikaciju

Accuracy

Procenat tačnih predikcija. Intuitivna, ali može biti zavarađujuća na neuravnoteženim skupovima.

F1 Score

Harmonijska sredina preciznosti i odziva. Bolja metrika kada su klase neuravnotežene.

Metrike za regresiju

MSE

Mean Squared Error. Kažnjava velika odstupanja. Osetljiv na autlajere.

MAE

Mean Absolute Error. Prosečna apsolutna greška. Robusniji na autlajere od MSE.

Proces kreiranja modela i primene

Svaki deep learning projekat prati standardizovani tok rada koji vodi od sirovih podataka do modela u produkciji. Razumevanje ovog toka je ključno za svakog praktičara.

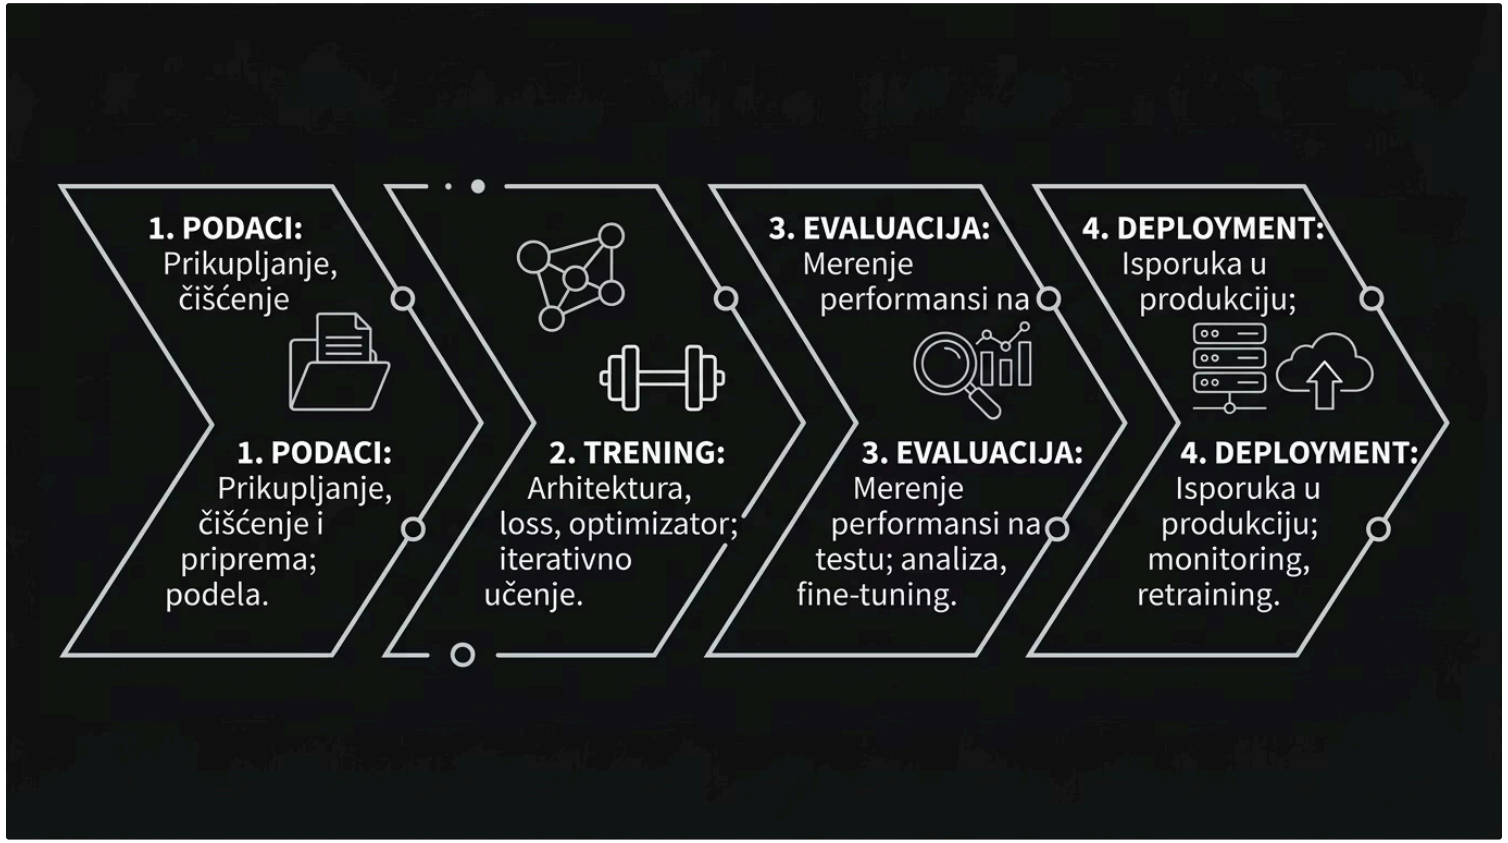

Ovaj ciklus često nije pravolinijski— rezultati evaluacije često nas vraćaju na prethodne korake radi poboljšanja podataka, arhitekture ili hiperparametara.

Zaključak

Deep learning je moćan alat, ali uspeh nije slučajan — zavisi od **tri stuba** koji moraju raditi u skladu.

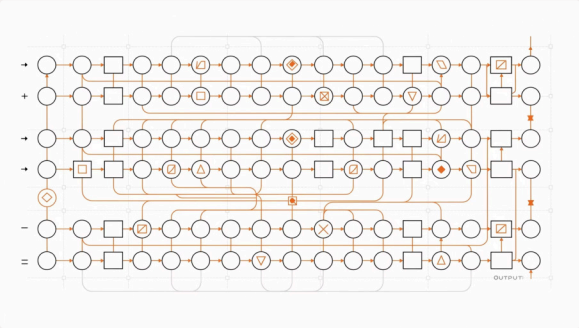

Arhitektura

Pravi izbor slojeva, aktivacionih funkcija i strukture mreže postavlja osnovu svakog modela.

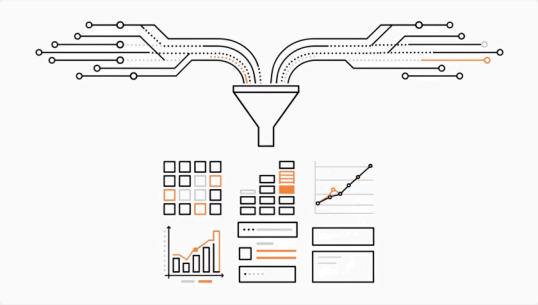

Podaci

Kvalitetni, dovoljno brojni i dobro pripremljeni podaci su gorivo bez kog ni najbolja arhitektura ne može da uči.

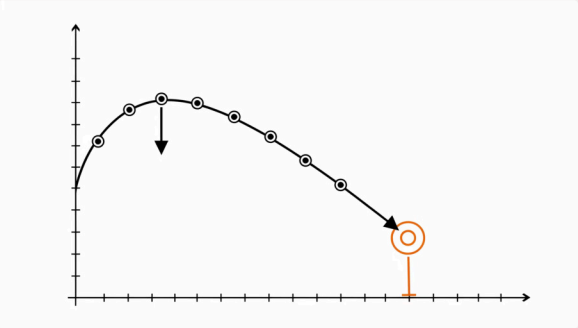

Optimizacija

Pravi optimizator, pažljivo podešen learning rate i dobra evaluacija osiguravaju da model konvergira ka rešenju.

Ovo su osnove — svaka od ovih tema zaslužuje dublje istraživanje. Morate da eksperimentišete, jer je praksa jedini put do razumevanja! 🚀