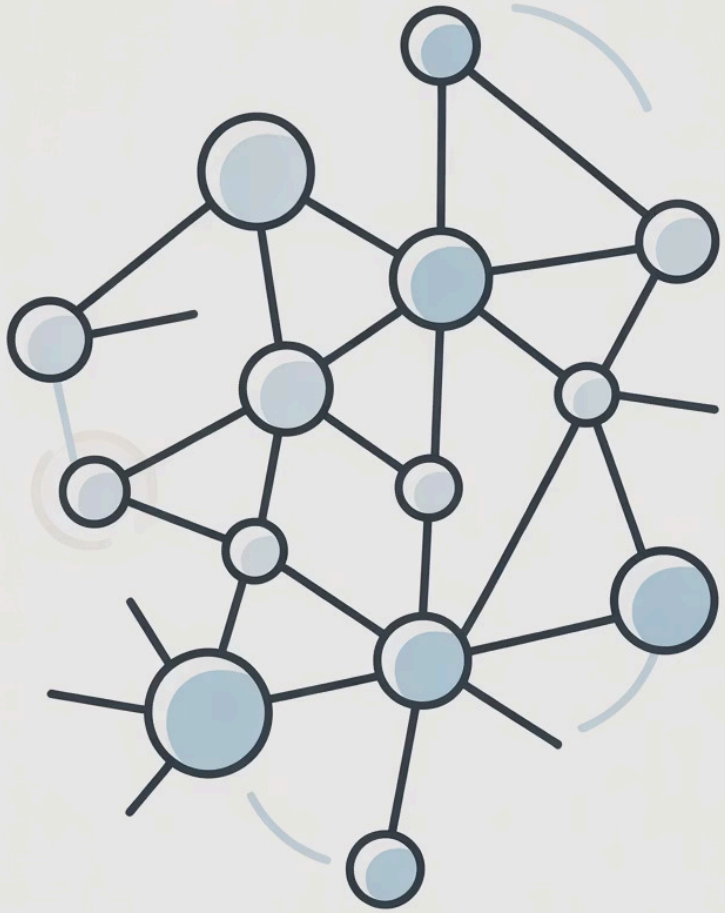

Linearna regresija pomoću neuronskih mreža: od osnova do predikcije

Predmet: Duboko učenje i neuronske mreže

Predavanje 2

Prof dr Zoran Ševarac, FON

Šta je linearna regresija?

Linearna regresija je jedan od osnovnih alata u mašinskom učenju. Cilj je pronaći **linearni odnos** između ulaznih podataka i izlazne numeričke vrednosti koju želimo da predvidimo.

Osnovna Formula

Model je definisan jednačinom:

$$y = wx + b$$

gde je
y predviđena vrednost,
x ulazni podatak,
w težina (nagib linije), i
b pomak (bias — presek sa y-osom).

Šta Model Uči?

Tokom treninga, model automatski pronalazi optimalne vrednosti za **w** i **b** koje opisuju vezu između ulaza i izlaza sa što manjom **greškom**.

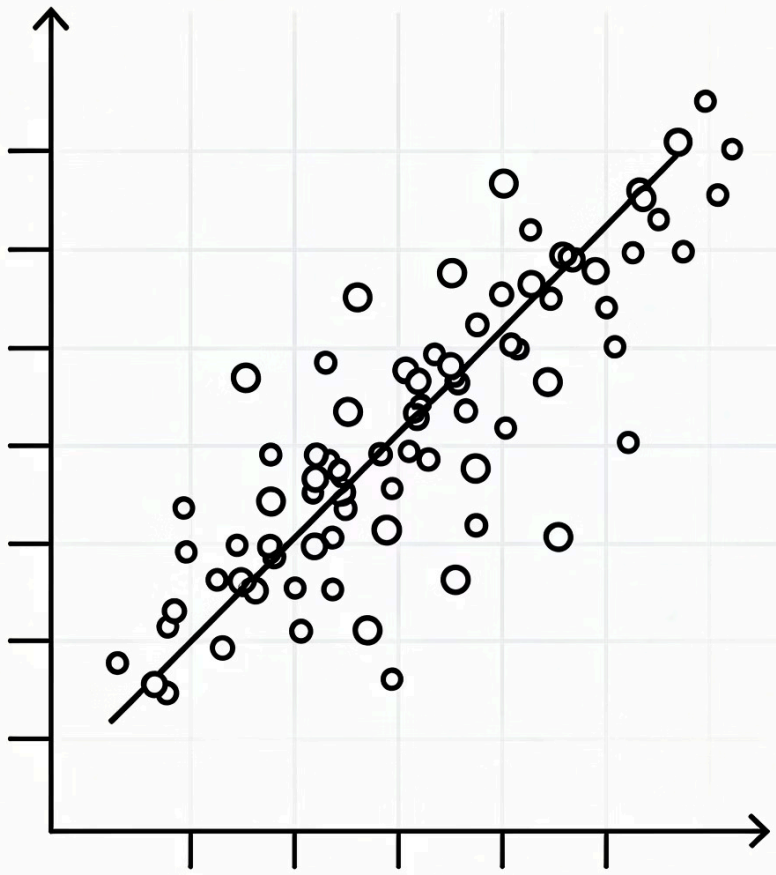

Neuronske mreže za linearnu regresiju

Iako zvuče kompleksno, neuronske mreže za linearnu regresiju su u suštini **samo linearni modeli** — ali sa moćnim principomza učenje parametara automatski.

Ulazni Podaci (x)

Ulazne vrednosti koje dovodimo u model — npr. površina stana, godine starosti, temperatura.

Množenje Težinom (w)

Ulaz se množi sa odgovarajućom težinom **w**. Težine određuju jačinu uticaja ulaza i nagib linije.

Dodavanje Pomaka (b)

Dodaje pomak **b** koji modelu daje fleksibilnost da se prilagodi podacima.

Izlaz — Predikcija (ŷ)

Rezultat je predviđena vrednost $\hat{y} = wx + b$, koju poredimo sa stvarnom vrednošću.

Funkcija greške: srednja kvadratna greška (MSE)

Da bi model učio, mora znati **koliko greši**. MSE (Mean Squared Error) je najčešće korišćena funkcija greške u linearnoj regresiji. Ona meri prosečan kvadrat razlike između predviđene vrednosti (**ŷ**) i stvarne vrednosti (**y**).

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Kvadriranje grešaka obezbeđuje da su **sve greške pozitivne** i da se veće greške više kažnjavaju. Cilj treninga je minimizovati MSE što je više moguće.

Zašto se koristi kvadrat greške?

- Eliminiše negativne vrednosti greške
- Penalizuje velika odstupanja više nego mala
- Matematički pogodna za diferenciranje
- Daje glatku, konveksnu funkciju koja se lako minimizuje

Vizualizacija MSE: Brdo Greške

Zamislite **trodimenzionalno brdo** gde svaka tačka na površini predstavlja određeni par vrednosti **(w, b)** i njima odgovarajuću MSE grešku. Naš cilj je pronaći **najnižu tačku** tog brda — globalni minimum. Na toj tački, model ima najmanju moguću grešku na skupu podataka za trening.

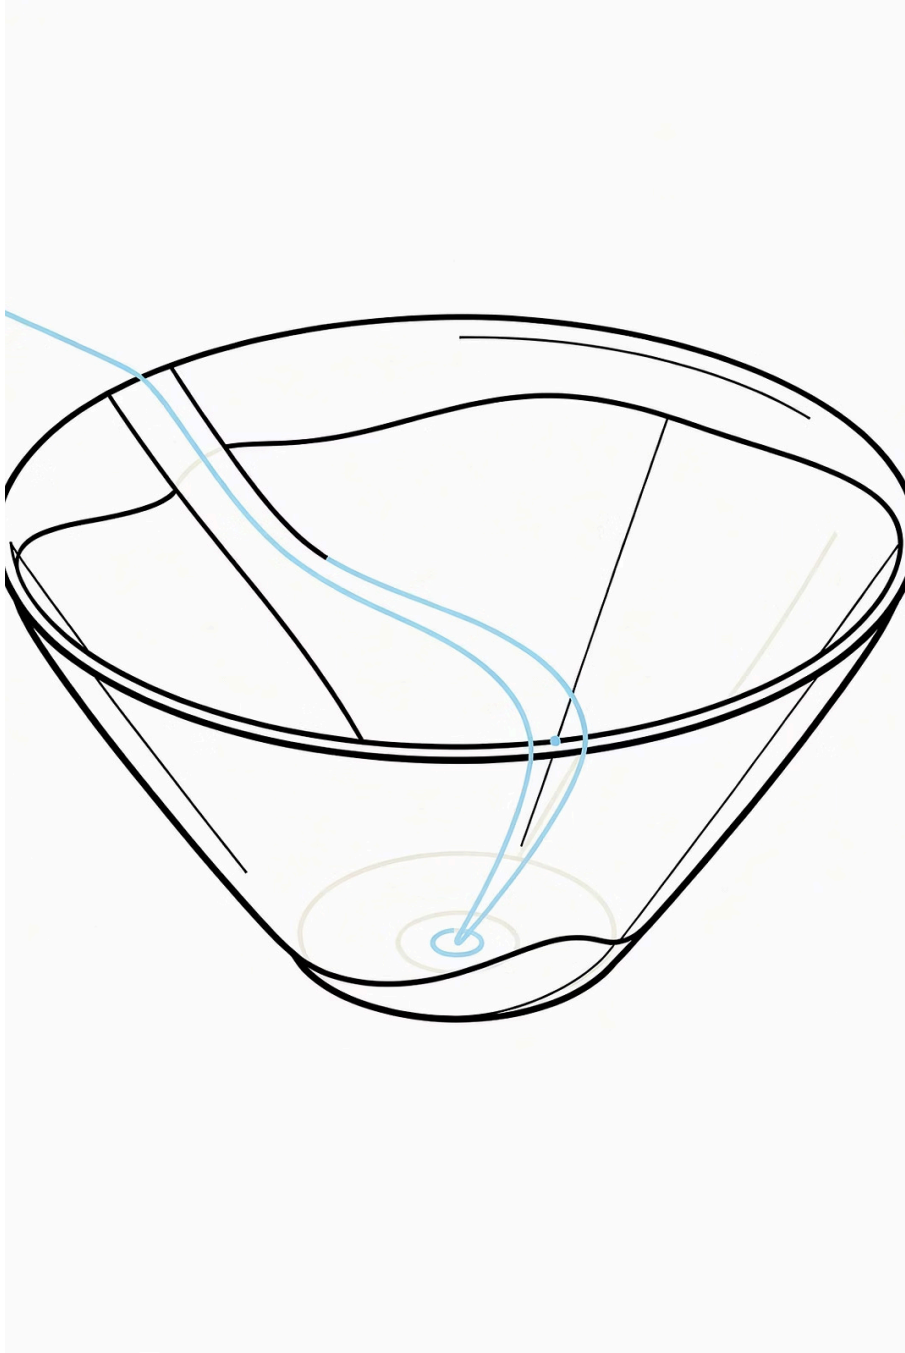

Gradijentni Spust: Spuštanje Niz Brdo

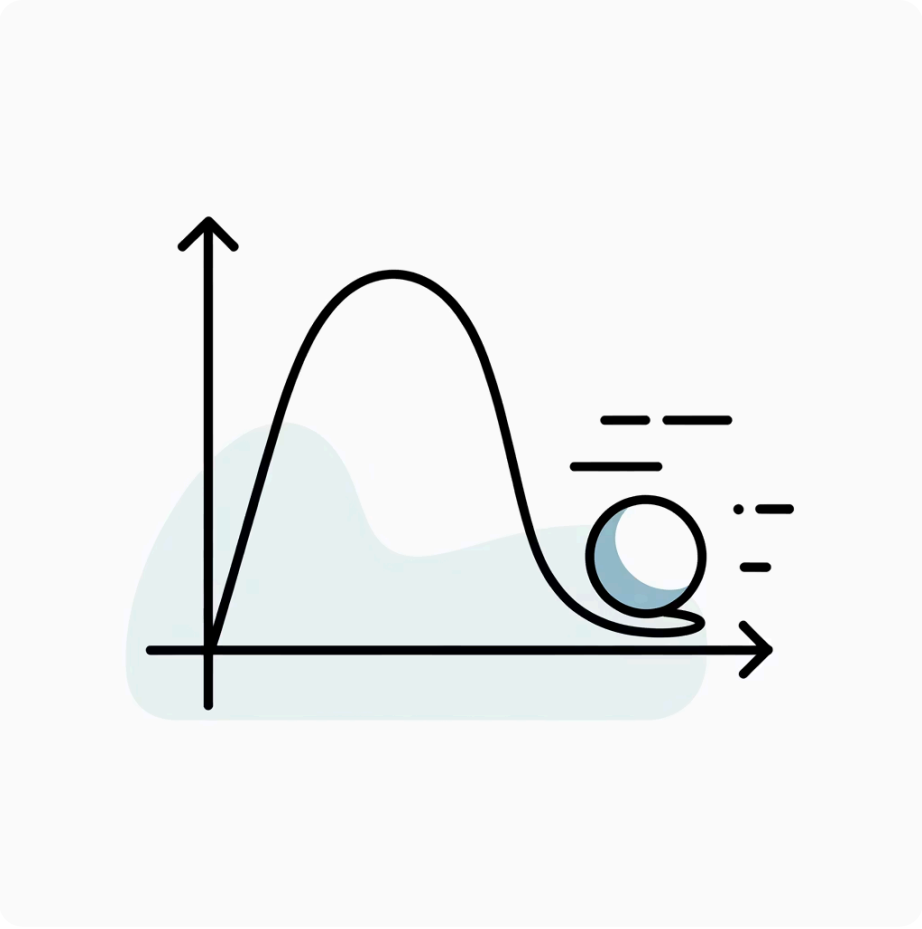

Gradijentni spust (Gradient Descent) je iterativni algoritam koji pronalazi minimum funkcije greške. Metafora je jednostavna: zamislite da stojite na brdu u magli i treba da dođete do dna. Pravite male korake u smeru **najvećeg pada terena**.

Gradijent = Nagib

Parcijalne derivacije MSE po **w** i **b** govore nam u kom smeru greška raste najbrže.

Suprotni Smer

Krećemo se u **suprotnom smeru** od gradijenta — tamo gde greška opada.

Izvod MSE: Kako Izračunamo Gradijent?

Da bismo primenili gradijentni spust, moramo izračunati parcijalne derivacije MSE po parametrima w i b. Ovo nam govori u kom smeru i za koliko treba da korigujemo parametre.

Izvod po w

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Pošto je $\hat{y}_i = wx_i + b$, dobijamo:

$$\frac{\partial \text{MSE}}{\partial w} = -\frac{2}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i) \cdot x_i$$

Gradijent po w zavisi od greške pomnožene sa ulazom x.

Izvod po b

$$\frac{\partial \text{MSE}}{\partial b} = -\frac{2}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)$$

Gradijent po b je prosečna greška — koliko se predviđanja sistematski razlikuju od stvarnih vrednosti.

Negativan predznak u izvodima znači da gradijent pokazuje smer rasta greške. Zato od parametara oduzimamo gradijent — krećemo se u suprotnom smeru, prema minimumu.

Ažuriranje Parametara sa Gradijentnim Spustom

Srce gradijentnog spusta su **formule za ažuriranje parametara**. Nakon svakog prolaza kroz podatke, parametri **w** i **b** se koriguju u pravcu koji smanjuje grešku:

Ažuriranje Težine w

$$w = w - \alpha \cdot \frac{\partial MSE}{\partial w}$$

Težina se smanjuje za vrednost gradijenta pomnoženu sa koeficijentom učenja.

Ažuriranje Pomaka b

$$b = b - \alpha \cdot \frac{\partial MSE}{\partial b}$$

Isti princip važi i za pomak — korigujemo ga proporcionalno gradijentu i koeficijentu učenja **α**.

Oznaka **α (alfa)** predstavlja **koeficijent učenja** (learning rate) — jedan od najvažnijih hiper-parametara modela. On kontroliše veličinu svakog koraka prema minimumu.

Koeficijent Učenja (Learning Rate — α)

⚡ Preveliki α

Model pravi **prevelike korake** i preskače minimum. Greška može da osciluje ili čak da raste umesto da pada — nestabilno učenje.

✅ Optimalni α

Model se **stabilno i efikasno** spušta prema minimumu. Greška opada ravnomerno kroz svaku epohu treninga.

🐌 Premali α

Model napreduje izuzetno **sporo**. Trening traje dugo i može da ostane "zaglavljen" u lokalnom minimumu.

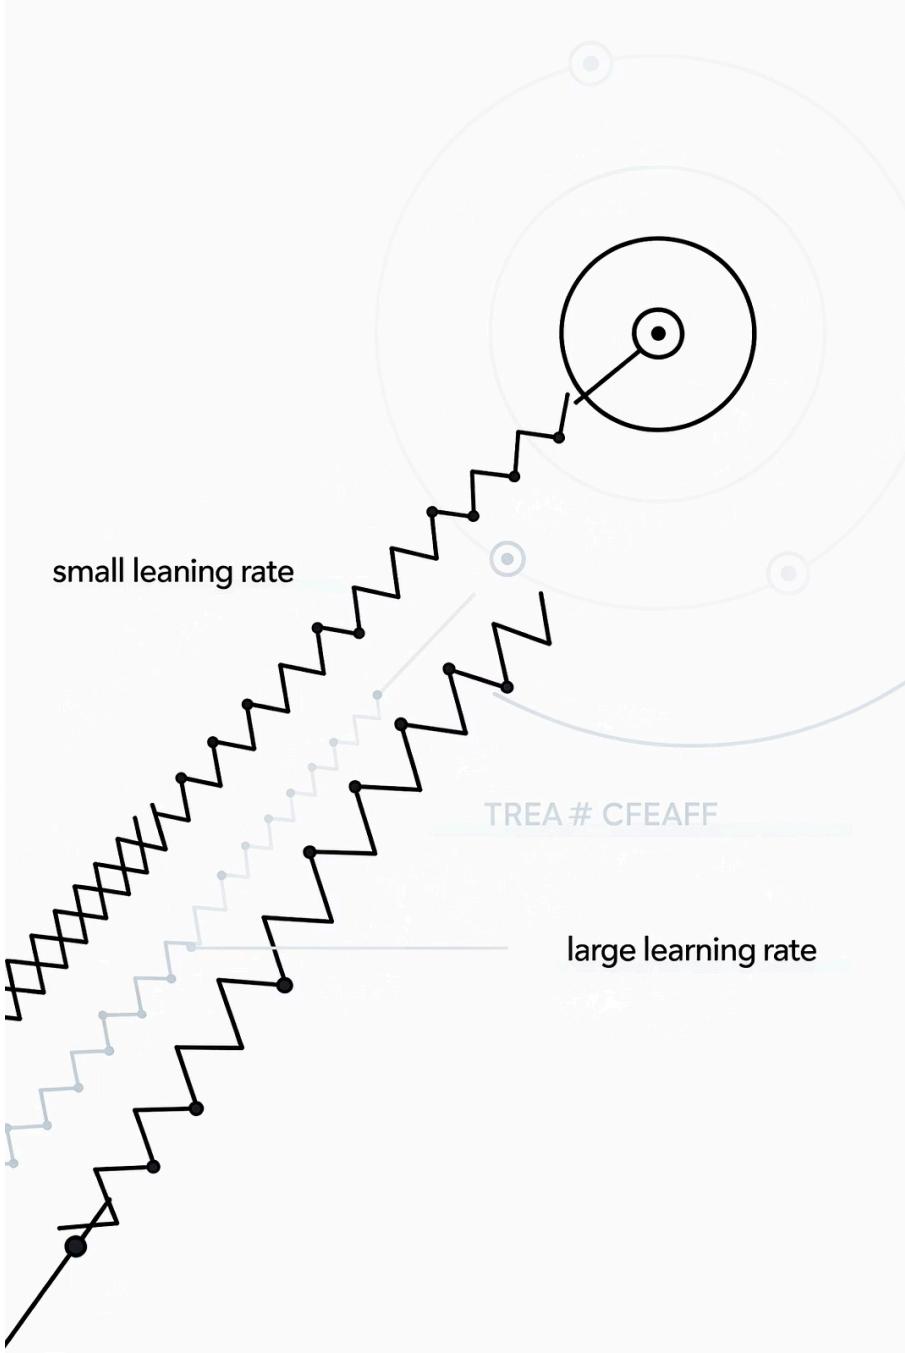

Uticaj Learning Rate-a na Konvergenciju

Grafik prikazuje kako se MSE greška smanjuje kroz epohe treninga u zavisnosti od vrednosti koeficijenta učenja α.

⚡ Preveliki α

Greška osciluje ili raste — model preskače minimum i divergira. Trening je nestabilan.

✅ Optimalni α

Greška ravnomerno i brzo opada prema minimumu. Stabilna i efikasna konvergencija.

🐌 Premali α

Greška sporo opada kroz mnogo epoha. Trening je spor i može zaglaviti pre minimuma.

Izbor pravog learning rate-a je ključan — preporučuje se testiranje vrednosti poput 0.1, 0.01, 0.001 i praćenje krive greške kroz epohe.

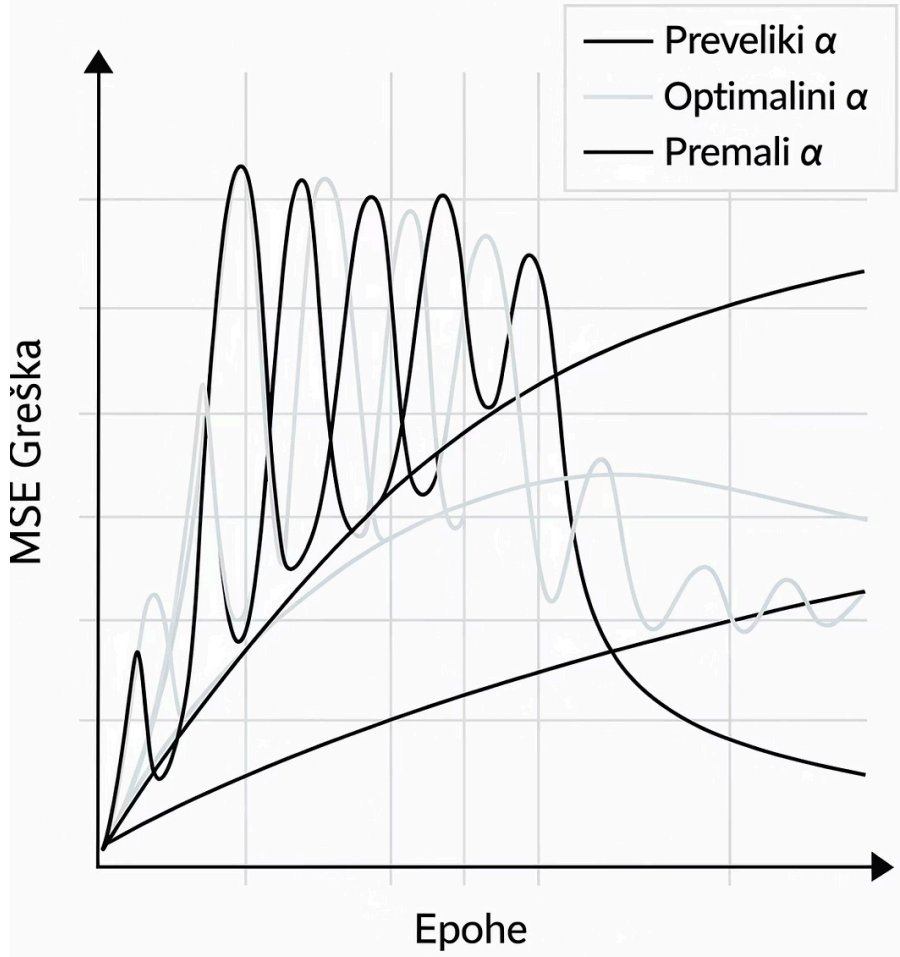

Proces Učenja u Praksi

Trening linearne regresije je **iterativni ciklus** koji se ponavlja sve dok greška ne dostigne zadovoljavajuće nisku vrednost. Svaka iteracija kroz ceo skup podataka naziva se **epoha**.

1

Inicijalizacija

Postavljamo **w** i **b** na male, slučajne vrednosti (obično blizu nule).

2

Predikcija (Forward Pass)

Za sve ulazne podatke izračunavamo predviđene vrednosti $\hat{y} = wx + b$.

3

Izračunavanje Greške

Računamo **MSE** između predviđenih i stvarnih vrednosti — merimo koliko model greši.

4

Gradijent (Backward Pass)

Izračunavamo parcijalne derivacije $\partial MSE / \partial w$ i $\partial MSE / \partial b$ da znamo pravac korekcije.

5

Ažuriranje Parametara

Primenjujemo formule gradijentnog spusta — korigujemo **w** i **b** prema gradijentu i koeficijentu učenja.

6

Ponavljanje (Epohe)

Koraci 2–5 se ponavljaju **stotinama ili hiljadama puta** dok se greška ne stabilizuje na minimumu.

Zaključak: Od Jednostavne Linije do Predikcije

Linearna regresija pomoću neuronskih mreža otkriva srž mašinskog učenja. Razumevanjem tri ključna koncepta, dobijamo čvrst temelj za sve složenije modele:

MSE — Mera Greške

Kvantifikuje koliko model odstupa od stvarnosti. Minimizacija MSE je cilj svakog treninga.

Gradijentni Spust

Iterativni algoritam koji vodi parametre prema minimumu funkcije greške korak po korak.

Koeficijent Učenja α

Balansira brzinu i stabilnost učenja. Ključni hiper-parametar koji određuje uspeh treninga.
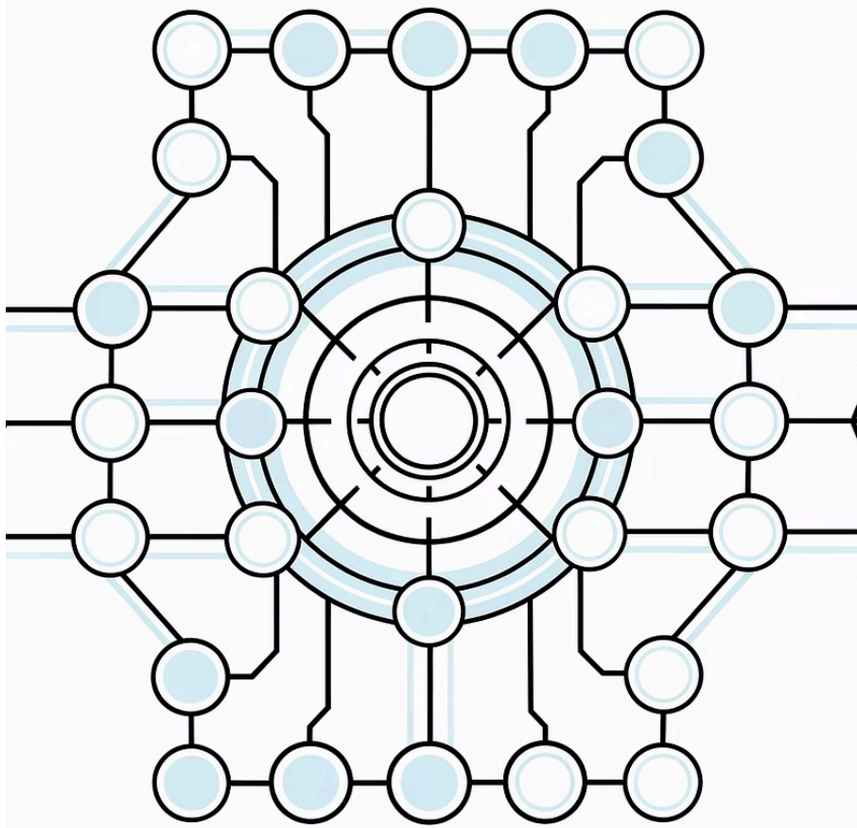
🚀 Ovo je **temelj dubokog učenja** — isti principi se primenjuju u višeslojnim neuronskim mrežama, konvolucionim mrežama i transformerima koji stoje iza modernih AI sistema.